

گزارشکار تمرین دوم عملیه ماشین لرنینگ

1) الف:

ما یک دیتا ست از یک سری اطلاعاتی که در یک hotel جمع اوری شده است را در دسترس داریم , هدف ما این است که از روی این دیتا , Average daily rate را تخمین بزنیم.

یک دیتا ست برای train و validation به ما داده شده است و دیگری برای test .

میخواهیم که از یک mlp استفاده کنیم.

برای اینکه داده های categorical را به عدد تبدیل کنیم , از لایبری پانداس استفاده میکنیم:

```
pd.Categorical
```

یک فانکشن به نام convert_to_cat زدم که در آن تمام دیتا های categorical را به عدد تبدیل میکنیم:

سپس از آن بخش train را میگیریم:

```
train_df,categorical_index=convert_to_cat(df)
```

شافل کردن دیتا ست:

```
train_df=train_df.sample(frac=1)
print(train_df)
```

جدا کردن دیتا ست:

میدانیم که میخواهیم ADR را پیشبینی کنیم, پس y ما همان ADR است, فقط چون دو وسط دیتا ست است , مجبوریم که دیتا ست را دو تیکه کنیم, و سپس concat کنیم:

```
final_x_1=pd.DataFrame(train_df).iloc[:,24]
final_x_2=(pd.DataFrame(train_df).iloc[:,25:])
final_x=pd.concat([final_x_1, final_x_2], axis="columns")
final_y=pd.DataFrame(train_df).iloc[:,24]
print(final_x)
```

نرمالایز کردن دیتا:

برای نرمالایز کردن دیتا سعی کردم که از لایبری استفاده نشود و فقط از std و میانگین دیتا استفاده کردم :

```
mean=final_x.mean()
standard_deviation=final_x.std()
final_x= (final_x - mean) / standard_deviation
print(final_x)
```

حالا به صورت sequential لایه هایمان را اضافه میکنیم:

```
model = keras.models.Sequential()
model.add(Dense(64, input_shape=input_shape, activation='relu'))

model.add(Dense(64, activation='relu'))

model.add(Dense(1))

# Configure the model and start training
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=0.01),
              loss='mean_squared_error',
              metrics=['MAE'])
history_1=model.fit((final_x), final_y, epochs=30, batch_size=64, verbose=1)
history_2=model.fit((final_x), final_y, epochs=50, batch_size=64, verbose=1)
# history_3=model.fit((final_x), final_y, epochs=100, batch_size=250, verbose=1)
```

حالا لایه ها را fit میکنیم، و میگذاریم که train شود:

(1)ب:

حالا برای plot کردن loss این فانکشن را زدیم:

اول باید از history استفاده کنیم، تا اطلاعات را بیرون آورده و در یک لیست بزاریم:

```
loss_list = [s for s in history.history.keys() if 'loss' in s and 'val' not in s]
val_loss_list = [s for s in history.history.keys() if 'loss' in s and 'val'
in s]
acc_list = [s for s in history.history.keys() if 'acc' in s and 'val' not in
s]
val_acc_list = [s for s in history.history.keys() if 'acc' in s and 'val' in
s]
mae_list=[s for s in history.history.keys() if 'mean_absolute_error' in s and
'val' not in s]
val_mae_list = [s for s in history.history.keys() if 'mean_absolute_error' in
s and 'val' in s]
```

بعد هم باید پلات کنیم:

```
## Loss
plt.figure(1)
for l in loss_list:
    plt.plot(epochs, history.history[l], 'b', label='Training loss (' +
str(str(format(history.history[l][-1], '.5f'))+'))')
for l in val_loss_list:
    plt.plot(epochs, history.history[l], 'g', label='Validation loss (' +
str(str(format(history.history[l][-1], '.5f'))+'))')

plt.title('Loss')
plt.xlabel('Epochs')
plt.ylabel('Loss')
plt.legend()



## mae
plt.figure(2)
for l in mae_list:
    plt.plot(epochs, history.history[l], 'b', label='mean_absolute_error (' +
str(str(format(history.history[l][-1], '.5f'))+'))')
# for l in val_acc_list:
#     plt.plot(epochs, history.history[l], 'g', label='Validation accuracy (' +
+ str(str(format(history.history[l][-1], '.5f'))+'))')

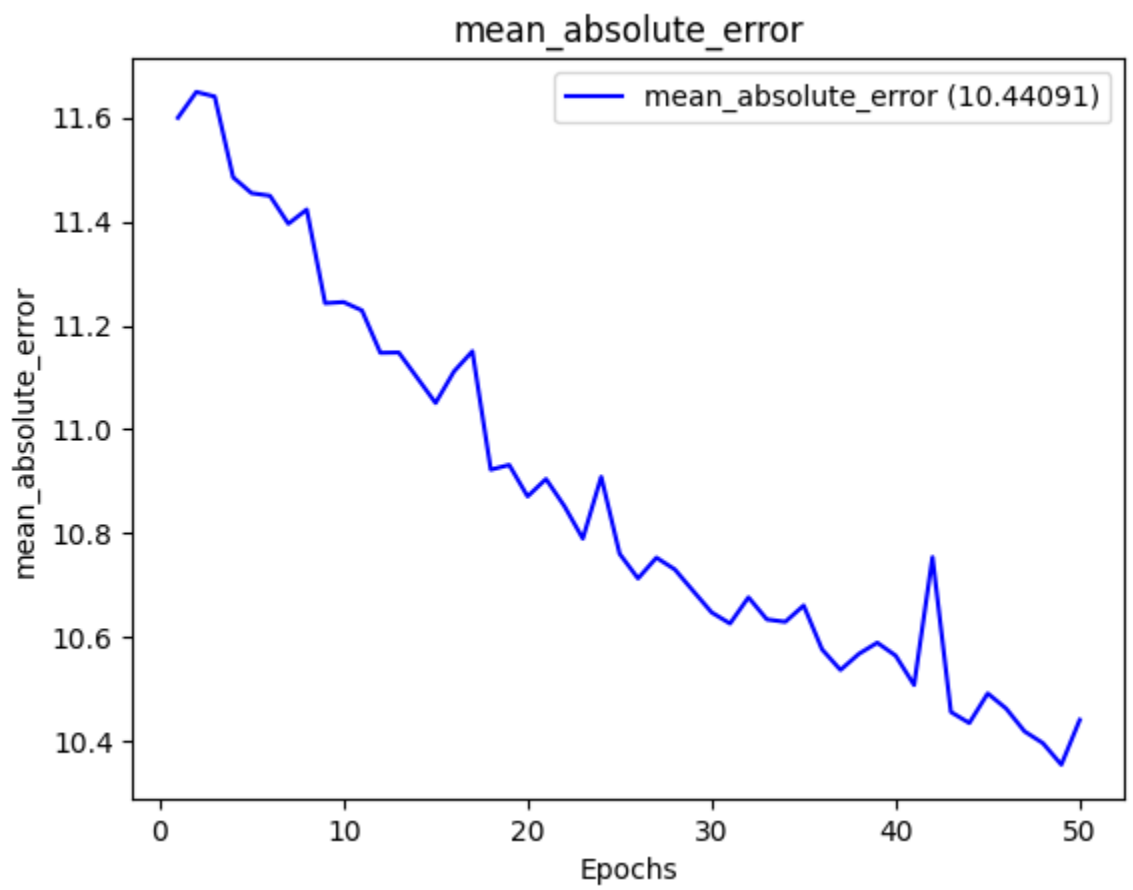
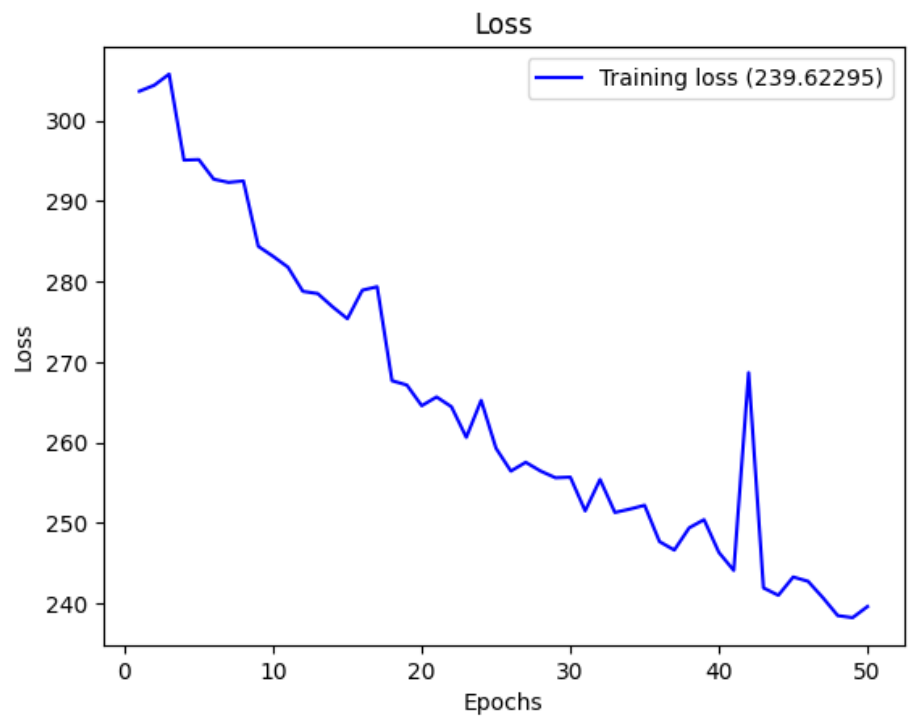
plt.title('mean_absolute_error')
plt.xlabel('Epochs')
plt.ylabel('mean_absolute_error')
plt.legend()
plt.show()
```

همه ی این کار ها را در یک فانکشن به اسم زیر قرار دادم:

```
def plot_history(history):
```

figure های زیر را بدست آوردیم:





1ج:

حالا باید دیتای تست رو وارد کنیم:

```
df_2 = pd.read_csv("H2.csv")
df_2=df_2.dropna()
test_df,categorical_index_2=convert_to_cat(df_2)
final_x_1_2=pd.DataFrame(test_df).iloc[:,24]
final_x_2_2=(pd.DataFrame(test_df).iloc[:,25:])
test_x=pd.concat([final_x_1_2, final_x_2_2], axis="columns")
test_y=pd.DataFrame(test_df).iloc[:,24]
print(test_x)
```

```
mean=test_x.mean()
standard_deviation=test_x.std()
test_x= (test_x - mean) / standard_deviation
print(test_x)
```

حالا جواب ها را predict میکنیم و بعد آن ها را درون فایل save میکنیم:

```
y_pred=model.predict(test_x)
```

```
csv_write=pd.concat([pd.DataFrame(y_pred), pd.DataFrame(test_y)], axis="columns")
csv_write.to_csv("./comp.csv")
```

حالا مقدار اختلاف را به دو روش مختلف در آورديم:

```
from sklearn.metrics import mean_squared_error
print(mean_squared_error(pd.DataFrame(y_pred), pd.DataFrame(test_y)))
model.evaluate(test_x,test_y)
```

نتیجه:

1):د:

برای این بخش از select k best, library استفاده کردیم، که خودش برایمان این کار را انجام میدهد:

```
from sklearn.feature_selection import SelectKBest
# from sklearn.feature_selection import chi2
from sklearn.feature_selection import SelectKBest, f_regression
select_reg = SelectKBest(k=4, score_func=f_regression)
select_reg.fit(final_x, final_y)
X_train_housing_new = select_reg.transform(final_x)
X_train_housing_new.shape
```

```
kept_features = pd.DataFrame({'columns': final_x.columns,
                              'Kept': select_reg.get_support()})
kept_features
```

مثلا 10 تا مهم ترین feature, feature های زیر هستند:

| | columns | Kept |
|----|-----------------------------|-------|
| 0 | IsCanceled | False |
| 1 | LeadTime | False |
| 2 | ArrivalDateYear | False |
| 3 | ArrivalDateMonth | True |
| 4 | ArrivalDateWeekNumber | True |
| 5 | ArrivalDateDayOfMonth | False |
| 6 | StaysInWeekendNights | False |
| 7 | StaysInWeekNights | False |
| 8 | Adults | True |
| 9 | Children | True |
| 10 | Babies | False |
| 11 | Meal | True |
| 12 | Country | False |
| 13 | MarketSegment | True |
| 14 | DistributionChannel | True |
| 15 | IsRepeatedGuest | False |
| 16 | PreviousCancellations | False |
| 17 | PreviousBookingsNotCanceled | False |
| 18 | ReservedRoomType | True |
| 19 | AssignedRoomType | True |
| 20 | BookingChanges | False |
| 21 | DepositType | False |
| 22 | DaysInWaitingList | False |
| 23 | CustomerType | False |
| 24 | RequiredCarParkingSpaces | False |

(2)

ما چون کلاس مقدمه ی هوش داریم , این بخش رو یکبار انجام داده بودیم , پس کمی خلاصه توضیح میدم و بیشتر فقط نتایج رو میزارم.

این لایه های ماست:

```
# return model
model = tf.keras.Sequential()

# VGG_1
model.add(tf.keras.layers.Conv2D(32, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same', input_shape=input_shape))
model.add(tf.keras.layers.BatchNormalization())
model.add(tf.keras.layers.Conv2D(32, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same', input_shape=input_shape))
model.add(tf.keras.layers.BatchNormalization())
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
model.add(tf.keras.layers.Dropout(0.2))

# Output
model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(128, activation='relu',
kernel_initializer='he_uniform'))
model.add(tf.keras.layers.BatchNormalization())
model.add(tf.keras.layers.Dropout(0.5))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
return model
```

یا همان»

Model: "sequential_5"

| Layer (type) | Output Shape | Param # |
|---|--------------------|---------|
| ===== | | |
| conv2d_8 (Conv2D) | (None, 32, 32, 32) | 896 |
| ===== | | |
| batch_normalization_9 (Batch Normalization) | (None, 32, 32, 32) | 128 |

conv2d_9 (Conv2D) (None, 32, 32, 32) 9248

batch_normalization_10 (Batch Normalization) (None, 32, 32, 32) 128

max_pooling2d_5 (MaxPooling2D) (None, 16, 16, 32) 0

dropout_6 (Dropout) (None, 16, 16, 32) 0

flatten_5 (Flatten) (None, 8192) 0

dense_12 (Dense) (None, 128) 1048704

batch_normalization_11 (Batch Normalization) (None, 128) 512

dropout_7 (Dropout) (None, 128) 0

dense_13 (Dense) (None, 10) 1290

=====

Total params: 1,060,906

Trainable params: 1,060,522

Non-trainable params: 384

حالا fit میکنیم لایه ها را با مدل مون:

Train on 50000 samples

Epoch 1/6

50000/50000 [=====] - 134s 3ms/sample - loss: 0.7869 - acc: 0.7257

Epoch 2/6

50000/50000 [=====] - 134s 3ms/sample - loss: 0.7215 - acc: 0.7485

Epoch 3/6

50000/50000 [=====] - 133s 3ms/sample - loss: 0.6714 - acc: 0.7658

Epoch 4/6

50000/50000 [=====] - 134s 3ms/sample - loss: 0.6317 - acc: 0.7785


Epoch 5/6


50000/50000 [=====] - 128s 3ms/sample - loss: 0.5924 - acc: 0.7912

Epoch 6/6

s 3ms/sample - loss: 0.5581 - 140 - [=====] 50000/50000
acc: 0.8017

حالا نمودار ها را میکشیم:







Digit [2]




Categorical distribution. Model prediction: 4




Digit [5]




Categorical distribution. Model prediction: 5



Digit [4]




Categorical distribution. Model prediction: 4




Digit [0]




Categorical distribution. Model prediction: 0




Digit [9]



Digit [8]



Digit [2]



Digit [5]

